

EXTRACTION DES BESOINS POUR CDC

Projet Data / Big Data — Prédiction dans le domaine de la santé

Objectif : recueillir les informations nécessaires pour concevoir une solution Data/Big Data capable de préparer, analyser et exploiter des données de santé afin de produire des prédictions fiables, sécurisées et exploitables.

1. Identification du projet

Nom du projet : _____

Client / organisme : _____

Responsable métier : _____

Responsable Data / technique : _____

Date et version : _____

2. Contexte et problématique

Quel problème de santé souhaite-t-on étudier ou anticiper ?

Pourquoi une prédiction est-elle nécessaire ?

Quelle solution existe actuellement et quelles sont ses limites ?

Quelles conséquences peut avoir une mauvaise prédiction ?

3. Objectif de la prédiction

Quel événement ou résultat doit être prédit ?

Quel est l'horizon de prédiction ?

Quel niveau de performance est attendu ?

Comment la prédiction sera-t-elle utilisée par les utilisateurs ?

4. Parties prenantes et utilisateurs

Professionnels de santé : _____

Data scientists / ML engineers : _____

Data engineers : _____

Responsables métier : _____

Qui consulte les prédictions et qui prend les décisions ?

5. Sources et données

Quelles sont les sources disponibles ?

■ Dossiers patients ■ Laboratoires ■ Imagerie ■ Objets connectés

■ Bases hospitalières ■ Registres ■ Données publiques ■ Autre

Origine / propriétaire des données : _____

Formats : CSV / JSON / SQL / API / autres.

Fréquence de mise à jour : _____

Volume et période historique : _____

6. Variables et cible

Variable cible (target) : _____

Variables explicatives : _____

Nombre de patients / observations : _____

Variables sensibles : _____

Valeurs manquantes / anomalies connues : _____

7. Qualité et préparation

Comment traiter les valeurs manquantes ?

Comment supprimer les doublons et incohérences ?

Comment traiter les valeurs aberrantes ?

Faut-il normaliser ou transformer certaines variables ?

Comment traiter le déséquilibre des classes ?

Comment contrôler la qualité avant entraînement ?

8. Pipeline Data / Big Data

Étapes attendues : ingestion → stockage → nettoyage → transformation → analyse → entraînement → prédiction.

Traitement : ■ Batch ■ Temps réel ■ Les deux

Outils envisagés : ■ Python ■ SQL ■ Spark ■ Airflow ■ Kafka ■ Docker ■ Cloud

Faut-il automatiser et surveiller le pipeline ?

9. Stockage et architecture

Type de stockage : _____

Base SQL / NoSQL / Data Lake / Data Warehouse : _____

Architecture cible : _____

Environnement : local / serveur / cloud / hybride.

Stratégie de sauvegarde : _____

10. Modèle prédictif

Type : ■ Classification ■ Régression ■ Série temporelle ■ Autre

Modèles à étudier : ■ Logistic Regression ■ Random Forest ■ XGBoost ■ Réseau neuronal ■ Autre

Comment choisir le meilleur modèle ?

Le modèle doit-il être explicable ? _____

11. Évaluation

Métriques : accuracy, precision, recall, F1-score, ROC-AUC, MAE, RMSE, etc.

Métrique prioritaire : _____

Performance minimale acceptable : _____

Comment éviter la fuite de données (data leakage) ?

Comment constituer train / validation / test ?

12. Sécurité et confidentialité

Quelles données sont personnelles ou sensibles ?

Qui peut accéder aux données brutes et aux prédictions ?

Authentification et autorisations : _____

Chiffrement requis : _____

Journalisation / audit : _____

Quelles obligations légales et réglementaires s'appliquent ?

13. Éthique, biais et explicabilité

Quels biais peuvent affecter les prédictions ?

Comment vérifier les performances entre différents groupes ?

Comment expliquer une prédiction à l'utilisateur ?

Faut-il afficher un niveau de confiance ?

Qui valide l'utilisation des prédictions ?

14. Déploiement et exploitation

Mode de déploiement : ☐ API ☐ Application ☐ Dashboard ☐ Autre

Fréquence des prédictions : _____

Faut-il surveiller la dérive des données / du modèle ?

Comment déclencher le réentraînement ?

Quelles alertes doivent être générées ?

15. Exigences non fonctionnelles

Temps de réponse maximal : _____

Disponibilité : _____

Nombre d'utilisateurs / requêtes : _____

Scalabilité : _____

Traçabilité et audit : _____

Maintenabilité et documentation : _____

16. Contraintes et planning

Budget : _____

Date de début : _____

Date de livraison : _____

Technologies imposées : _____

Contraintes d'infrastructure / compétences : _____

17. Livrables attendus

- ☐ Dataset nettoyé et documenté
- ☐ Pipeline Data automatisé
- ☐ Modèle prédictif
- ☐ Rapport d'évaluation
- ☐ API / service de prédiction
- ☐ Dashboard
- ☐ Documentation technique et utilisateur
- ☐ Guide de déploiement
- ☐ Rapport final / présentation

18. Tableau de synthèse des exigences

ID	Type	Exigence	Priorité	Critère d'acceptation
PRED-01	Prédiction		Haute	
DATA-01	Données		Haute	
PIPE-01	Pipeline		Haute	
MODEL-01	Modèle		Haute	
SEC-01	Sécurité		Haute	
ETH-01	Éthique		Moyenne	

19. Checklist de validation avant rédaction du CDC

- Problématique et objectif de prédiction définis.
- Utilisateurs et parties prenantes identifiés.
- Sources, variables et cible identifiées.
- Volume et qualité des données évalués.
- Pipeline Data défini.
- Modèles et métriques d'évaluation définis.
- Sécurité et confidentialité définies.
- Biais, explicabilité et gouvernance considérés.
- Déploiement, monitoring et réentraînement prévus.
- Livrables, planning et critères d'acceptation validés.

Attention : dans un projet de prédiction en santé, la performance technique du modèle ne suffit pas. Le CDC doit aussi préciser la confidentialité, la gouvernance, les biais, l'explicabilité, la validation métier et les conditions d'utilisation des prédictions.